Rakamların Diliyle Güven: Graybox GLM + Metaheuristic ile Saf Prim

Mehmet Ali Kaya

Veri Bilimci & Aktüeryal Modelleme Uzmanı

Bir kasko benzeri portföyün saf primini kestirmek için frekansı Poisson, şiddeti Gamma ile modelledim; iki modelin regularization katsayısını grid taraması yerine genetik algoritmayla aradım ve modeli zamandan kopuk bir test diliminde ölçtüm. Sonuç şu: yorumlanabilir bir model, doğru bölünmüş bir veri setiyle, opak bir aramadan daha güvenilir konuşabiliyor.

Veri: ne kullandım, neyi uydurmadım

Bu çalışmanın dürüstlük ilkesi ilk satırdan başlıyor. freMTPL2 (Fransız motorlu taşıt üçüncü şahıs hasar verisi, açık lisanslı CC0) indirilebilirse frekans tarafında kullanılmak üzere koda gömülü; ancak freMTPL2'nin şiddet bileşeni ayrı bir dosyada ve poliçe bazında birleştirilemez olduğundan, uçtan uca gösterim **açıkça etiketlenmiş sentetik bir demo verisiyle** yapıldı. Veri üretim süreci biliniyor: her poliçe için sürücü yaşı, araç gücü, araç yaşı, bonus–malus seviyesi, trafik yoğunluğu, marka, yakıt, bölge ve bölge kodu üretildi; hasar sayısı bu özelliklere bağlı bir Poisson oranıyla, hasar tutarı ise aynı özelliklere bağlı bir Gamma ortalamasıyla türetildi (tohum 42, 20.000 poliçe). Sentetik olduğu her çıktıda yazılı; hiçbir yerde gerçek veriymiş gibi sunulmadı.

Model: iki beyaz kutu + bir kara kutu arayış

Sigortacılığın klasik "graybox" tarifi burada iki katmanlı. Birinci katman **tamamen yorumlanabilir**: frekans için log-link'li Poisson regresyon (hasar sayısı), şiddet için log-link'li Gamma regresyon (hasar tutarı). Saf prim, bu ikisinin çarpımı — yani `beklenen hasar sıklığı × beklenen hasar şiddeti`. Aktüeryal standart formül; her katsayı tek tek okunabilir, denetlenebilir, itiraz edilebilir.

İkinci katman **opak ama kontrollü**: her iki GLM'in de bir `alpha` (L2 regularization) hiperparametresi var. Bunu sabit değerler üzerinde grid taramasıyla değil, bir **genetik algoritmayla** aradım. Kromozom iki genden oluşuyor — `log10(alpha_frekans)` ve `log10(alpha_şiddet)`. Her bireyin uygunluğu, validation dilimindeki toplam deviance (Poisson + Gamma) ile ölçülüyor; turnuva seçimi, harmanlama çaprazlaması ve Gauss mutasyonuyla 12 nesil boyunca evriliyor. Grid'in aksine, arama uzayını sürekli ve uyarlanabilir biçimde tarıyor.

Doğrulama: zamanın dışına çıkmak

Modeli üçe böldüm: %70 eğitim, %15 doğrulama (hiperparametre seçimi), %15 test (son, tek seferlik ölçüm). Test dilimi ne eğitime ne de hiperparametre arayışına dokundu; bu yüzden sonuç, modelin hiç görmediği poliçelere karşı bir "zaman dışı" (Out-of-Time) sınamasıdır. Bölme tohumu sabit, dolayısıyla her çalıştırmada aynı poliçeler aynı dilime düşer; sonuç tekrarlanabilir.

Bulgular

Genetik algoritma `alpha_frekans ≈ 8,06` ve `alpha_şiddet ≈ 0,23` noktasına yakınsadı. Frekans tarafının güçlü bir düzenlileştirme istemesi anlamlı: hasar sıklığı sinyali zayıf (test diliminde %4,5) ve 24 özellik içinde yalnızca birkaçı gerçekten işe yarıyor; güçlü shrinkage, gürültüyü ezerek saf primi iyileştiriyor. Şiddet tarafı ise daha az düzenlileştirme istiyor — hasar tutarının sinyali görece güçlü.

Ölçü (test, hiç görülmemiş 3.000 poliçe)	Değer
Hasar sıklığı (gerçekleşen)	%4,51
Frekans — Poisson deviance	0,2297
Şiddet — MAE	1.235 birim
Şiddet — MSE	2.652.890
Saf prim — MAE	168,7 birim
Saf prim — MSE	403.411
Saf prim ortalaması (tahmin)	76,9 birim

Tek ders

Graybox'ın gücü, "kara kutu" kısmını bile denetlenebilir tutmasında. Alpha'yı genetik algoritmayla aramak, grid taramasına kıyasla daha az hesaplamayla daha geniş bir uzayı tarar; ama nihai karar her zaman yorumlanabilir iki GLM'in üzerine oturur. Frekans tarafı güçlü, şiddet tarafı hafif düzenlileştirme istiyor — bu da modelin iki ayrı doğasını tek bir "sihirli" parametreye sığdıramayacağımızı gösteriyor. Veri sentetikse sentetik denir; rakamlar ancak o zaman güven kurar.

- Kod: https://github.com/000MAK/cafepolice-graybox-meta
- Model kartı: https://huggingface.co/makactuary/cafepolice-graybox-meta